

1. Книшод Софія
Фольварочна Софія
2. Наша задача полягала в тому, щоб порівняти алгоритми Краскала та Прима. Для початку ми використали функцію `gnp_random_connected_graph`, щоб сформувати граф, а потім алгоритми, які будуть представлені нижче. Також щоб провести експеримент ми вирішили провести два порівняння. Перший раз ми вирішили порівняти швидкість виконання алгоритму з бібліотеки `networkx`, а другий раз наших алгоритмів.
3. Специфікація комп'ютера:
 - Кількість ядер: 6
 - Тактова частота: 2.38 GHz
 - Установлена фізична пам'ять: 8 ГБ(доступно для використання: 7,42 ГБ)
 - ОС: Майкрософт Windows 10 Pro
4. Програмний код алгоритмів
Для алгоритму Прима для зручності запис даних перетворено в матрицю:

```
def turn_into_matrix(number, compl):  
  
list_of_edges=list(gnp_random_connected_graph(number,compl).edges.data('weight'))  
adjacencyMatrix = [[0 for column in range(number)] for row in range(number)]  
for i,j,k in list_of_edges:  
    adjacencyMatrix[i][j]=k  
    adjacencyMatrix[j][i]=k  
return adjacencyMatrix
```

```
def prim(adjmatrix):  
    selected_node=[False]*len(adjmatrix)# we create a list of selected nodes  
  
    total=0  
    counter=0#count nodes until we pick all of them  
    selected_node[0]=True # we pick the first node
```

```

while counter<len(adjmatrix)-1:#we create cycle which will go through
all the vertices tied to the selected until you find the min weight
min=999999999 #we create a big number to compare with weight
u=0
v=0
for i in range(len(adjmatrix)):
    if selected_node[i]:#pick selected node
        for j in range(len(adjmatrix)):
            if ((not selected_node[j]) and adjmatrix[i][j]):
                #pick not selected vertex, which creates an edge
with our vertex
                if min > adjmatrix[i][j]:
                    min = adjmatrix[i][j]#we assign the value of
the least weight and compare everything else with it
                    u = i
                    v = j
total+=adjmatrix[u][v]#add min weight of edge if it exists, else 0
selected_node[v] = True#assign another vertex value True, so it is
picked
counter+=1#add 1, as we pick one more node
return total

```

Алгоритм Краскала:

```

def kruskal_alg(edges_ls:list):
    """
    the Kruskal algorithm
    """

    # since we take G = gnp_random_connected_graph(...,draw=True),
    # take edges_ls as G.edges(data=True)
    # edges_ls looks like: [(11, 12, {'weight': 7}), ...]
    # step 1: sorting the edges by weight
    sorted_edg_ls = sorted(edges_ls, key=lambda x: x[2]['weight'])

    # creating containers of joined nodes,
    # isolated, independent nodes groups
    # and final result edges of Kruskal algorithm
    joined, group, result_edges = set(), dict(), list()

```

```

    one_group = True # assume everything is in one connected group as
nodes are connected
    for edge in sorted_edg_ls:
        first_node = edge[0]
        second_node = edge[1]
        # join all the nodes to some joined group; in result, we get
several independent structures of connected nodes
        if first_node not in joined or second_node not in joined: # if
both are already connected, there is a risk of creating a cycle
            if first_node not in joined and second_node not in joined:
                group[first_node] = group[second_node] = [first_node,
second_node] # add both nodes to group dictionary
            else:
                if first_node not in group.keys(): # first
node is not in a group
                    group[second_node].append(first_node) # put it
in the group with the second node
                    group[first_node] = group[second_node]
                else:
                    group[first_node].append(second_node) # second
node is not in the group, put it in the group with node 1
                    group[second_node] = group[first_node]
                # since we have connected two nodes appropriately, add this
pair to the resulting graph
                result_edges.append(edge)
                joined.add(first_node)
                joined.add(second_node)

    # now join the groups of nodes we got
possible_connection_ls = []
    for edge in sorted_edg_ls:
        first_node = edge[0]
        second_node = edge[1]
        if second_node not in group[first_node]: # nodes are in
different groups
            one_group = False
            possible_connection_ls.append(edge)
    if one_group is False:

```

```

        final_join = sorted(possible_connection_ls, key=lambda x:
x[2]['weight'])
        result_edges.append(final_join[0])
        min_sum = 0
        for elem in result_edges: # count sum of the resulting graph
            min_sum += elem[2]['weight']
        return min_sum

```

5. Програмний код експерименту:

- Для алгоритму з networkx

```

def counting_time(nodes, NUM_OF_ITERATIONS, alg):
    time_taken = 0
    for i in tqdm(range(NUM_OF_ITERATIONS)):

        # note that we should not measure time of graph creation
        G = gnp_random_connected_graph(nodes, 0.1, False)

        start = time.time()
        tree.minimum_spanning_tree(G, algorithm=alg)
        end = time.time()

        time_taken += end - start
    return time_taken

def draw_graph(dct1, dct2):
    row_1=list(dct1.keys())
    row_2=list(dct1.values())
    plt.plot(row_1, row_2, 'r', marker='o', label="Алгоритм Прима")
    row_1=list(dct2.keys())
    row_2=list(dct2.values())
    plt.plot(row_1, row_2, 'b', marker='o', label='Алгоритм Краскала')
    plt.title('Часова ефективність алгоритмів')
    plt.xlabel('Розмірність графу')
    plt.ylabel('Час роботи')
    plt.legend()

dict_of_results={}
dict_of_results[10]=counting_time(10,1000,'prim')
dict_of_results[20]=counting_time(20,1000,'prim')

```

```
dict_of_results[50]=counting_time(50,1000,'prim')
dict_of_results[100]=counting_time(100,1000,'prim')
dict_of_results[200]=counting_time(200,1000,'prim')
dict_of_results[250]=counting_time(250,1000,'prim')
dict_of_results[500]=counting_time(500,1000,'prim')
dict_of_results[1000]=counting_time(1000,1000,'prim')
second={}
second[10]=counting_time(10,1000,'kruskal')
second[20]=counting_time(20,1000,'kruskal')
second[50]=counting_time(50,1000,'kruskal')
second[100]=counting_time(100,1000,'kruskal')
second[200]=counting_time(200,1000,'kruskal')
second[250]=counting_time(250,1000,'kruskal')
second[500]=counting_time(500,1000,'kruskal')
second[1000]=counting_time(1000,1000,'kruskal')
draw_graph(dict_of_results,second)
```

- Для наших алгоритмів

```
def counting_time(nodes, NUM_OF_ITERATIONS):
    time_taken = 0
    for i in tqdm(range(NUM_OF_ITERATIONS)):

        G = turn_into_matrix(nodes,0.1)

        start = time.time()
        prim(G)
        end = time.time()

        time_taken += end - start
    return time_taken
def counting_time_2(nodes,NUM_OF_ITERATIONS):
    time_taken = 0
    for i in tqdm(range(NUM_OF_ITERATIONS)):

        G=gnp_random_connected_graph(nodes,0.1)

        start = time.time()
        kruskal_alg(G.edges(data=True))
        end = time.time()
```

```

        time_taken += end - start
    return time_taken

def draw_graph(dct1,dct2):
    row_1=list(dct1.keys())
    row_2=list(dct1.values())
    plt.plot(row_1, row_2, 'r', marker='o', label="Алгоритм Прима")
    row_1=list(dct2.keys())
    row_2=list(dct2.values())
    plt.plot(row_1, row_2, 'b', marker='o', label='Алгоритм Краскала')
    plt.title('Часова ефективність алгоритмів')
    plt.xlabel('Розмірність графу')
    plt.ylabel('Час роботи')
    plt.legend()

    plt.show()

dict_of_results={}
dict_of_results[10]=counting_time(10,1000)
dict_of_results[20]=counting_time(20,1000)
dict_of_results[50]=counting_time(50,1000)
dict_of_results[100]=counting_time(100,1000)
dict_of_results[200]=counting_time(200,1000)
dict_of_results[250]=counting_time(250,1000)
dict_of_results[500]=counting_time(500,1000)

second={}
second[10]=counting_time_2(10,1000)
second[20]=counting_time_2(20,1000)
second[50]=counting_time_2(50,1000)
second[100]=counting_time_2(100,1000)
second[200]=counting_time_2(200,1000)
second[250]=counting_time_2(250,1000)
second[500]=counting_time_2(500,1000)

draw_graph(dict_of_results,second)

```

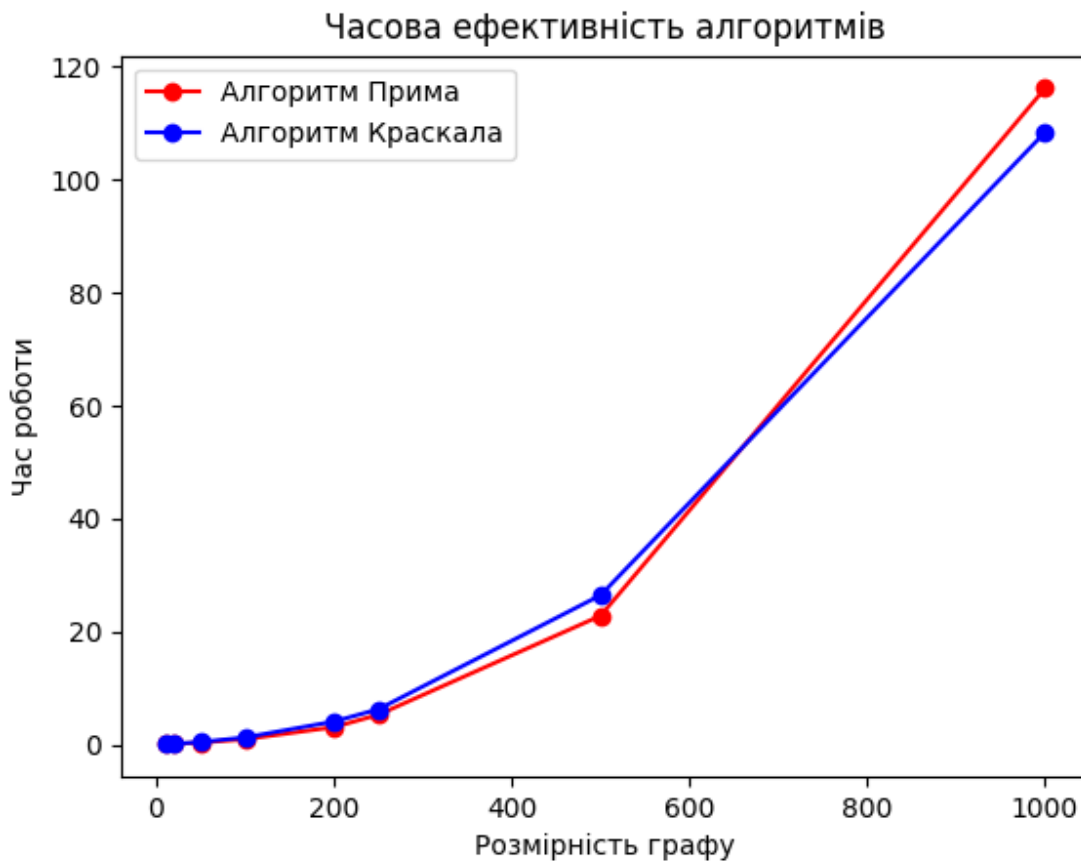
6. Це дані для алгоритму networkx при 1000 ітераціях:

Прима:

{10: 0.05402374267578125, 20: 0.10562992095947266, 50: 0.32158660888671875, 100: 0.9235556125640869, 200: 2.995626926422119, 250: 5.184518337249756, 500: 22.76223611831665, 1000: 115.60192441940308}

Краскала:

{10: 0.07300257682800293, 20: 0.12403130531311035, 50: 0.4360785484313965, 100: 1.2289187908172607, 200: 4.091622591018677, 250: 6.3779332637786865, 500: 25.425278425216675, 1000: 108.12357997894287}



На графіку ми можемо побачити, що спочатку різниця між часом виконання є мінімальною. При 500 вершинах Алгоритм Прима працює швидше, але вже при 1000 алгоритм Краскала виконується швидше.


Це дані для наших алгоритмів, але тут максимальна розмірність графа - 250 вершин, адже вони працюють набагато довше(особливо алгоритм Прима)

Прима:

{10: 0.026116609573364258, 20: 0.15837907791137695, 50: 2.0512471199035645, 100: 14.936888217926025, 200: 113.13581871986389, 250: 216.12461805343628}

Краскала:

{10: 0.026985645294189453, 20: 0.047014474868774414, 50: 0.18935418128967285, 100: 0.5981590747833252, 200: 2.2752010822296143, 250: 3.6132941246032715}



7. Загальний підсумок

Як ми можемо побачити на графі при кількості вершин <600, варто використовувати алгоритм Прима, адже він є швидшим. Коли кількість вершин є більшою, варто використовувати алгоритм Краскала. Але якщо використовувати наші алгоритми, то Краскала працює набагато швидше. Отже, найкращим є алгоритм Краскала, адже якщо використовувати networkx, то спочатку різниця в часі є мінімальною, а потім при більшій кількості вершин Краскала працює набагато швидше. І якщо використовувати наші алгоритми, то вибір очевидний, адже Краскала в будь-якому випадку працює набагато швидше і навіть краще ніж алгоритм з networkx.

Примітки до другого завдання:

Використана техніка взаємодії з pandas dataframe (на прикладі iris.data):

```
[[5.1 3.5 1.4 0.2]
 [4.9 3.  1.4 0.2]
 [4.7 3.2 1.3 0.2]
 [4.6 3.1 1.5 0.2]
 [5.  3.6 1.4 0.2]
 [5.4 3.9 1.7 0.4]
 [4.6 3.4 1.4 0.3]
 [5.  3.4 1.5 0.2]
 [4.4 2.9 1.4 0.2]
 [4.9 3.1 1.5 0.1]]
```

1. iris.data[:10] - беремо набір перших 10 значень
2. iris.data[:10, 3] - беремо значення з третьої колонки

```
[0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1]
(my_venv) sofia@DESKTOP-IQES72K: /mnt/d/different
```

3. iris.data[:10, 3]<0.3
 - ділимо dataframe на 2 частини за булевим "центральним" значенням

```
[ True  True  True  True  True False False  True  True  True]
(my_venv) sofia@DESKTOP-IQES72K: /mnt/d/different/discrete_lab$
```

4. Приклад розділу pandas dataframe з булевим значенням/ ~dataframe:

```

[ True True True True True True True True True True True True
 True True True True True True True True True True True True
 True True True True True True True True True True True True
 True True True True True True True True True True True True
 True True True True True True True True True True True True
 True True True True True False True True True True True False
 True True True True True True True True True True True True
 True True True True False False False False False False True False
 False False False False False False False False False False False False
 False True False True False False True True False False False False
 False False False False False False True False False False False False
 False False False False False False]

[False False False False False False False False False False False False
 False False False False False False False False False False False False
 False False False False False False False False False False False False
 False False False False False False False False False False False False
 False False False False False False False False False False False False
 False False False False False True False False False False False True
 False False False False False False False False False False False False
 False False False False True True True True True True True True True
 True True True True True True True True True True True True True
 True False True False True True False False True True True True True
 True True True True True True False True True True True True True
 True True True True True True]

```

Таким чином було здійснено поділ pandas dataframe на дві групи (у контексті роботи - піддерева). Таке зручне представлення дозволило систематизувати обробку можливих поділів дерева рішень, після чого було обрано найбільш оптимальний варіант (критерієм відбору був gini impurity індекс).